gtfs-ingest: Cambios recientes

Qué cambió desde el último commit, qué mejoró en los resultados y qué falta resolver en la conectividad

Víctor Rodríguez

26 de octubre de 2026

Cambios sin commit sobre `1df490a` · cifras de dos corridas completas con base de datos: `out_mibici_v2` (antes) y `out_mibici_v3` (ahora) · 2 feeds GTFS de Guadalajara + MiBici

En una diapositiva

Tres cambios principales, medidos en una corrida completa

1 MIBICI ENTRA AL ANÁLISIS

Ahora se puede agregar una lista simple de puntos (un CSV con id, nombre, latitud y longitud). Así entraron las **484 cicloestaciones de MiBici**.

2 MENOS DUPLICADOS FALSOS

La misma estación aparecía varias veces. Ahora se unen sus copias *reales*, pero ya **no se unen los andenes de sentidos opuestos**.

3 REPORTES MÁS CLAROS

El reporte dice qué reglas se usaron, las paradas cercanas sin línea ya no se ocultan, y hay 54 pruebas nuevas.

484

cicloestaciones MiBici

8,877 → 10,533

estaciones físicas contadas

285

pruebas que pasan

Lo que **no** cambió: rutas, horarios, frecuencias y la comparación con OpenStreetMap dan exactamente lo mismo que antes.

Vocabulario mínimo

Las palabras que se usan en el resto de la presentación

Feed	Un archivo de horarios de transporte (formato GTFS). Usamos dos: `improved` y `mdb`.
Parada (registro)	Un renglón con id, nombre y coordenadas. Una misma estación puede tener varios.
Estación física	El lugar real. Varias paradas-registro pueden ser la misma estación.
Duplicado (*dedupe*)	Paso que detecta registros que son la misma estación y los agrupa.
Enlace a pie	"Se puede caminar de A a B": paradas a menos de 300 m.
Red de estaciones	El grafo para calcular rutas: viajar en camión + caminar + transbordar.
Componente conectado	Un grupo de paradas que se pueden alcanzar entre sí. Lo ideal es **uno solo**.
Puente	Una conexión que, si se quita, parte la red en dos.

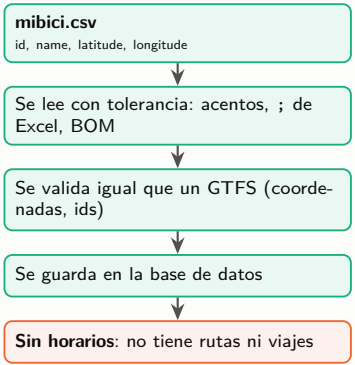
MiBici

Una lista de puntos que no es GTFS

Cómo entra · en qué resultados aparece · en cuáles no, y por qué

Una fuente de “solo paradas”

Antes el programa solo aceptaba feeds GTFS completos



- Sirve para cualquier inventario que no viene en GTFS: un levantamiento de campo, una hoja de Excel de una dependencia, MiBici.
- El CSV se tiene que **nombrar explícitamente**; nunca se toma solo de una carpeta (así no se vuelve a leer por error un resultado viejo).
- Si el encabezado no se entiende, el error dice qué columna falta y cómo nombrarla.
- La columna de capacidad de MiBici (`dpcapacity`) por ahora se ignora.

¿Dónde aparece MiBici y dónde no?

Una cicloestación es un lugar, no una parada de transporte

Resultado	¿MiBici?	Explicación sencilla
Inventario de paradas y mapa (GeoPackage)	**sí**	es un punto real del mapa
Lista de paradas cercanas (`near_stations.csv`)	**sí**	"¿qué transporte tengo a pie desde aquí?"
Red de estaciones y Neo4j	nodo	aparece, pero **sin enlaces a pie** (ver más adelante)
Detección de duplicados	**no**	una cicloestación nunca es "la misma estación" que un camión
Conexiones entre rutas, frecuencias	**no**	no tiene horarios

Cambio pequeño pero visible

Las paradas cercanas que no tienen línea ahora **sí** se listan, con un guion en lugar de la línea. Antes se ocultaban.

```
(13866, (GDL-001) C. Epigmenio..., -, 3)
(8782, Avenida 16 de Septiembre, C05, 3)
```

una cicloestación (línea "-") y un camión (línea C05), ambos a 3 min

Duplicados

La misma estación, contada varias veces

Las dos reglas · por qué el radio bajó de 50 m a 5 m
por qué MiBici quedó fuera · resultados

El problema: registros repetidos

Los dos feeds describen muchas estaciones iguales, y un feed incluso repite su propia línea con dos nombres de id:

```
improved:ST_02_018
   mdb:ST_02_018
mdb:SITEUR_002_018
```

3 registros, 0 m de distancia

$\Rightarrow$ **1 estación física**

Si no se unen: la estación se cuenta 3 veces y cada copia "ve" a las otras como vecinas a 1 minuto.

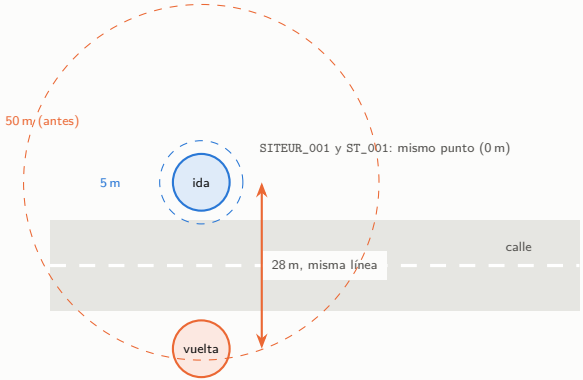
Dos reglas para unir registros

Entre feeds	distintos feeds, a $\leq$ 30 m, con nombre parecido **o** una línea en común
Mismo feed (nueva)	mismo feed, a $\leq$ **5 m**, con una línea en común (el nombre no basta)

Los registros nunca se borran: solo se agrupan, y cada grupo es una estación.

Por qué el radio bajó de 50 m a 5 m

Un duplicado está a 0 m; el andén del otro sentido está cruzando la calle



- Con **50 m**, la regla unía el andén de ida con el de vuelta: comparten la línea y están a 20–40 m.
- Eso convertía dos andenes en "una estación" y permitía **cambiar de sentido gratis** al calcular rutas.
- Con **5 m** solo se unen los registros realmente repetidos.

Medido

Pares del mismo feed: 2,697 (mediana 28.9 m) → **247** (todos entre 0 y 4.6 m).

MiBici fuera de duplicados y de los enlaces a pie

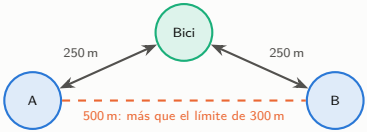
Dos riesgos que se cerraron por regla, no por suerte

DUPLICADOS

Una cicloestación llamada como una esquina, a menos de 30 m de una parada de camión con el mismo nombre, se podía unir a ella como "la misma estación".

No pasó en nuestros datos (0 casos) solo porque los nombres de MiBici empiezan con `(GDL-001)`. **Ahora MiBici se excluye de esa regla.**

ENLACES A PIE



Las cicloestaciones servían de "escalón" para caminar entre paradas lejanas. **Ahora no tienen enlaces a pie** en la red de estaciones.

0
cicloestaciones unidas a paradas

5,756 → 0
enlaces a pie con MiBici

1,901 → 0
atajos que solo existían por MiBici

Más claro y más consistente

Antes

- La línea de comandos usaba 50 m, pero el código (desde Python) tenía la regla apagada: **dos formas de correr, dos resultados**.
- El reporte decía “on (30 m)” y no decía si la segunda regla estaba activa.
- Las paradas cercanas sin línea no aparecían en las listas.

Ahora

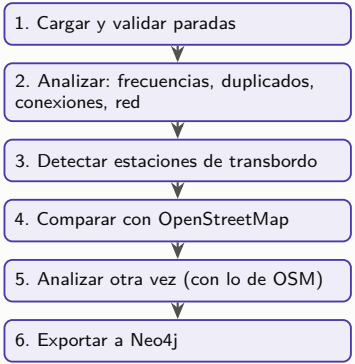
- Un solo valor (5 m) para la línea de comandos y el código, con una prueba que lo vigila.
- El reporte dice: *“on (cross-feed 30 m, within-feed 5 m)”*.
- Se listan con línea “-”.
- 54 pruebas nuevas; la documentación se revisa automáticamente en cada cambio.

Corrida completa

Antes contra ahora, con base de datos

6 pasos, unos 10 minutos · mismos feeds, mismas fechas, 300 m a pie por calles de OSM

Qué se corrió



Lo que quedó igual (buena señal)

- 274 rutas, 9,112 conexiones entre rutas, todas en un solo grupo
- horarios y frecuencias: idénticos
- OSM: 10,485 de 14,349 paradas encontradas (73.1 %)
- 2,708 zonas de transbordo, 71 multimodales

Los cambios solo tocan los duplicados y el papel de MiBici, como se buscaba.

Antes contra ahora

`out_mibici_v2` (radio 50 m, MiBici con enlaces) contra `out_mibici_v3`

Medida	Antes	Ahora	Qué significa
Estaciones físicas (de 14,349 registros)	8,877	**10,533**	ya no se juntan andenes opuestos
Grupos de duplicados	2,572	1,407	menos uniones, todas más seguras
Grupos con dos andenes del mismo feed a $>$15 m	1,658	**283**	$-$83 %; el resto viene de la otra regla
Grupo más grande	14	10	menos encadenamiento
Paradas sin ninguna vecina cercana	451	**196**	ahora "ven" el andén de enfrente
Enlaces a pie con MiBici	5,756	**0**	sin atajos artificiales
Grupos de la red (solo transporte)	50	50	la conectividad no empeoró
Conexiones ruta–ruta	9,112	9,112	175 cambian de tipo, ninguna se pierde

Pendientes

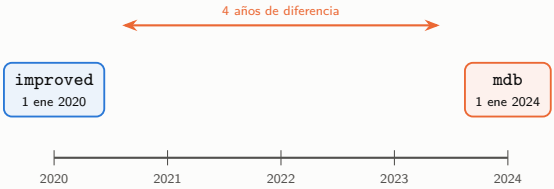
Lo que falta resolver en la conectividad

Ninguno rompe la corrida, pero todos cambian cifras que van al artículo

Resumen de pendientes

	Pendiente	En pocas palabras
ALTA	Fechas distintas entre feeds	un feed se analiza en 2020 y el otro en 2024
ALTA	Andenes opuestos aún unidos	283 grupos, por la regla entre feeds (hasta 30 m)
MEDIA	La red no está totalmente conectada	50 grupos; 111 paradas quedan fuera
MEDIA	Paradas de un solo sentido	86 paradas: se llega pero no se regresa (o al revés)
MEDIA	Red de rutas frágil en un punto	2 “puentes” en las variantes de la ruta T16B
BAJA	Depende del radio de 300 m	sin cercanía a pie, las rutas se parten en 6 grupos
BAJA	Muchos enlaces sobrantes	80 % de los enlaces a pie no cambian ningún tiempo

1. Los feeds se analizan en fechas distintas



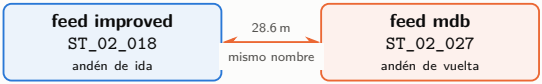
- Cada feed se analiza en su día más ocupado, y esos días no coinciden.
- Las conexiones entre los dos feeds mezclan horarios de **años distintos**.
- Ambos calendarios ya vencieron (2022 y 2024).

Qué hacer

Conseguir feeds actuales, o usar una fecha común (`--common-date`) si sus calendarios se traslapan; si no, decirlo en el artículo.

2. Andenes opuestos que siguen unidos

Ahora vienen de la regla *entre feeds*, que acepta hasta 30 m



Feeds distintos + nombre igual + $\leq$ 30 m
$\Rightarrow$ "misma estación"

- **283 grupos** todavía juntan dos andenes de un mismo feed separados más de 15 m.
- En la red, ese grupo se convierte en un **cambio de sentido gratis** (0 minutos).
- De los 4,376 pares entre feeds: 3,295 están a menos de 5 m y **1,081 entre 5 y 30 m**.

Qué hacer

Revisar una muestra de esos 1,081 pares y decidir un radio menor para esta regla.

3. La red de estaciones no está totalmente conectada

Contando solo paradas de transporte (13,865)



- Las 111 paradas que quedan fuera son del feed `mdb` y **ninguna tiene servicio** el día analizado; 21 no tienen ni un enlace.
- No es un error de cálculo: sin servicio y lejos de todo, no hay cómo llegar.
- Pero “50 grupos” suena peor de lo que es.

Qué hacer

Decidir si se excluyen de la red las paradas sin servicio ese día, o reportar “conectada sobre paradas con servicio”.

4. Paradas a las que se llega pero no se regresa

86 paradas dentro del grupo grande, sobre todo el ramal T16B1



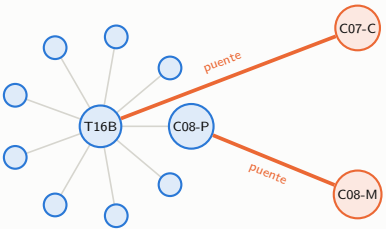
- En esa zona solo se camina entre paradas cercanas; la única unión con el resto es un tramo de camión que va en **una sola dirección**.
- Se puede llegar, pero el cálculo de rutas no encuentra cómo volver (o al revés).
- Puede ser real (un ramal) o un hueco en el feed.

Qué hacer

Revisar el ramal T16B1 en el feed: ¿falta el viaje de regreso?

5. Red de rutas: conectada, pero frágil en un punto

274 rutas, un solo grupo — pero dos conexiones sostienen a dos variantes



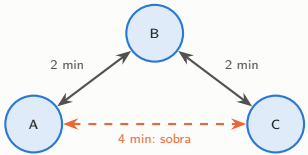
- Dos variantes de la ruta T16B (`T16B-C07-C`, `T16B-C08-M`) cuelgan de **una sola conexión** cada una. Si esa conexión fallara, quedarían aisladas.
- El resto de las rutas tiene en promedio 66 conexiones: mucho margen.
- Además, la red de rutas depende de la **cercanía a pie (300 m)**: sin ella se parte en 6 grupos.

Qué hacer

Confirmar las variantes T16B en el feed y justificar los 300 m en el artículo.

6. Muchos enlaces que sobran

No es un error: los tiempos salen bien, pero el grafo es más grande de lo necesario



Ir de A a C directo cuesta lo mismo que pasar por B.

- Se crea un enlace a pie entre **cada** par de paradas a menos de 300 m.
- El **80 %** de esos enlaces se podría quitar sin cambiar ningún tiempo de viaje (en minutos redondeados; 43 % medido en metros).
- 807 enlaces de “misma estación” también sobran.

Qué hacer

Opcional: una exportación “podada” para Neo4j y cálculos de rutas más rápidos.

Siguientes pasos

DECISIONES

1. ¿Qué fecha de servicio usar para los dos feeds?
2. ¿Qué radio usar para la regla entre feeds? (revisar 1,081 pares de 5–30 m)
3. ¿Se incluyen en la red las paradas sin servicio ese día?
4. ¿300 m es la distancia de transbordo que queremos defender?

TRABAJO TÉCNICO

1. Revisar el ramal T16B1 y las variantes T16B en el feed.
2. (Opcional) exportación podada de la red.
3. Actualizar README, guía y presentaciones con las cifras de `out_mibici_v3`.
4. Hacer commit de todo lo anterior (hoy nada está guardado en git).

Lo resuelto en esta ronda: MiBici integrada, duplicados más seguros, sin atajos artificiales y reportes que dicen exactamente qué se corrió.